Report - Praxisblatt 1

Malte A. Weyrich & Jan P. Hummel

May 9, 2024

Disclaimer

Alle Werte die in diesem Report vorgestellt werden, wurden auf einem *Lenovo-ThinkPad-Gen-1* Rechner mit folgender Hardware *AMD® Ryzen 7 pro 4750u with radeon graphics × 16; Memory: 16.0 GB* erhoben. Die Dokumentation zur *usage* der *SMSS JAR* ist auf dem **README.md** des folgenden *GitHub Repository:* `http://https://github.com/github4touchdouble/smss` zu finden.

1 Aufgabe

1.1 Naive Approaches

Der *naive* Ansatz verfolgt eine recht simple Strategie, um alle Segmente in dem Vector C zu identifizieren und die Summe zu bilden. Vom Arbeitsspeicher her ist dieser Ansatz sehr schonend, da die Variablen (wie z.B. *maxscore, l, r* usw.) immer einzeln gespeichert werden und gegebenen Falls überschrieben werden. Jedoch liegt der große Nachteil bei der Laufzeit, welche sich folgender maßen beschreiben lässt:

$$\frac{n^3 + 3n^2 + 2n}{6}$$

Der *rekursive* Ansatz spart sich einige Schritte in der Berechnung, jedoch bleibt der dominante Term weiterhin n^3:

$$\frac{n^3 - n}{6}.$$

Zudem leidet der Stack unter den polynomiell steigenden Funktionsaufrufen, was bereits bei kleinen Eingaben zu Problemen führt. Man könnte also argumentieren, dass obwohl der *rekursive* Ansatz auf dem Papier etwas effizienter ist, für große Eingaben immer noch der *naive* Ansatz am realistischen ist. Beide Algorithmen sind zeitlich eingeschränkt, vor allem ist aber der *rekursive* Ansatz klar limitiert (vom Arbeitsspeicher) was die Eingabegröße n an geht. In Abbildung 1 ist die Laufzeit in Sekunden beider Ansätze gegen die Eingabelänge n grafisch dargestellt:

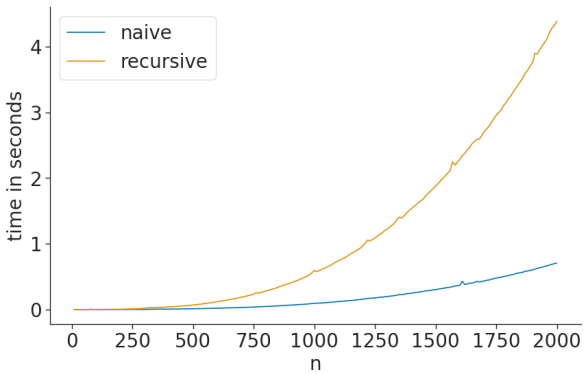

Figure 1: *Naive* algorithm versus *recursive* solution.

Wie sich herausstellt, skaliert der *naive* Ansatz auf der gegebene Hardware besser als der *rekursive* Ansatz. Das liegt wahrscheinlich an den vielen rekursiven Aufrufen, die alle ebenfalls Zeit kosten und daran, wie Java intern mit den Rekursionsaufrufen umgeht.

1.2 Dynamic Programming

Der *dynamic programming* Ansatz bedient sich eines Arrays, welches bereits berechnete Ergebnisse zwischenspeichert und somit redundante Berechnungen verhindert. Somit verbessert sich die Laufzeit stark verglichen zu den oberen Ansätzen:

$$\frac{n^2 + n}{2}.$$

Jedoch bußt dieser Ansatz damit ein, dass der Speicherplatzbedarf quadratisch steigt und das Array jedes mal initialisiert werden muss, was wiederum Zeit benötigt. Zudem ist die Nutzung des Arrays nicht optimal. Es wird jeweils nur die Hälfte des reservierten Speicherplatzes tatsächlich genutzt. In 2.3 wird diese Optimierung umgesetzt.

1.3 Divide and Conquer & Optimal Solution

Der *divide and conquer* hat eine Komplexität von .... TODO JAAAN

Der *optimale* Ansatz löst das Problem in linearer Zeit $\mathcal{O}(n)$. Genau wie im *naiven* Ansatz werden hier keine zusätzlichen Datenstrukturen verwendet, lediglich werden einzelne Integers gespeichert und überschreiben. Demnach ist der *optimale* Ansatz auch bezogen auf den Arbeitsspeicher sehr effizient.

2 Aufgabe

2.1 2a - SMSS

Wir erweitern den optimalen Ansatz, indem wir jedes gefundene *segment* in einer *ArrayList< ArrayList<int[3]> >* abspeichern. Die äußere Liste initialisiert für jeden neuen *max_score* der gefunden wurde eine neue innere Liste. Diese innere Liste wird so lange mit gleichwertigen *segmenten* befüllt, bis ein *segment* gefunden wurde, mit einen größerem *max_score*. So ist die Liste von links nach rechts aufsteigend nach *max_score* sortiert (d.h. die letzte innere Liste beinhaltet alle *MSS*). Am Ende wird einmal über die am *Endindex* stehende Liste in $\mathcal{O}(n)$ iteriert, um die tatsächlichen non overlapping *MSS* in einer finale Liste zu speichern.

Folgende Fälle werden abgedeckt:

```
CASE 1:
1: ---+===+-----------
2: ---+=====+---------
```

Hier darf das $segment_2$ nicht ausgegeben werden, da $segment_1 \subseteq segment_2$. Also merken wir uns jeweils den Start- und Endindex des letzten *segments*. So können wir die letzten Indizes mit den momentanen vergleichen und **CASE 1** abfangen.

```
CASE 2:
1: ---+=====+---------
2: ---+===+-----------
```

CASE 2 ist nicht möglich, da $segment_2$ vor $segment_1$ in der Liste abgespeichert ist. Der Algorithmus ist so konzipiert, dass er wie bei **CASE 1** erst das kürzere $segment_1$ findet und dann das längere $segment_2$. Also müssen wir uns nicht um **CASE 2** kümmern.

```
CASE 3:
1: -----+=+-----------
2: ---+=====+---------

CASE 4
```

```
1: ---+=====+---------
2: -----+=+-----------
```

CASE 3 & 4 Sind ebenfalls nicht möglich, da *MSS* entweder den gleichen Start- oder Endindex haben.

```
CASE 5:
1: -----+===+---------
2: ---+=====+---------
```

Hier wird sich in der *i-ten* Iteration die Start- und Endindizes von $segment_1$ gemerkt und demnach das $segment_2$ in der *i+1-ten* Iteration nicht dem Endresultat hinzugefügt, da der Endindex von $segment_2 \not> $ Endindex von $segment_1$.

2.2 2b - SMSS mit minimaler Länge

Wir verwenden den Algorithmus aus 2.1, um alle SMSS zu finden. Unser Ziel ist es, aus der Ergebnismenge von 2.1 die SMSS mit minimaler Länge zu ermitteln. Hierbei interessieren wir uns für die Länge jeder Sequenz in der Ergebnismenge sowie für die minimale Länge aller Sequenzen aus 2.1). Der Algorithmus durchläuft die Ergebnismenge aus 2.1 in linearer Zeitkomplexität $\mathcal{O}(n)$ und bestimmt für jede Sequenz die Länge anhand der Differenz zwischen ihrem Start- und Endindex in konstanter Zeit $\mathcal{O}(1)$. Während dieses Prozesses wird fortlaufend überprüft, ob die aktuelle Sequenz die bisher kürzeste ist, was ebenfalls in konstanter Zeit erfolgt $\mathcal{O}(1)$. Sequenzen gleicher Länge werden in einer Liste zusammengefasst, wobei die Sequenzlängen als Schlüssel in einer *HashMap* dienen. Dadurch ist ein schneller Zugriff gewährleistet, da der Zugriffsschlüssel (die Sequenzlänge) bekannt ist, was zu einer angenäherten Zugriffszeit von $\mathcal{O}(1)$ führ. Am Ende des Durchlaufs ist die minimale Sequenzlänge bekannt, und die Liste der Sequenzen mit dieser Länge kann durch einen Lesezugriff auf die *HashMap* als Ergebnismenge extrahiert werden. Mit zunehmender Größe der Eingabemenge steigt die Laufzeit von 2b) linear an. Jedes Element wird einmal gespeichert, wodurch auch die Speicherbelastung proportional mit der Größe der Eingabe wächst.

Anzumerken ist, dass die tatsächliche Laufzeit dieses Ansatzes auf der Konzeption und Implementierung von 2.1 abhängt. Eine Laufzeitkomplexität von 2.1 in $\mathcal{O}(n)$ ist vorausgesetzt, sodass die Laufzeitkomplexität von 2b) in $\mathcal{O}(n)$ liegt, da 2b) die Ergebnismenge aus 2.1 als Eingabe verarbeitet. Die Sortierung der Ergebnismenge aus 2.1 spielt keine Rolle, da allein aus der Kenntnis der minimalen Sequenzlänge nicht automatisch die Anzahl oder die Indexpositionen der SMSS mit minimaler Länge in der Ergebnismenge aus 2.1 folgen. Selbst wenn die Ergebnismenge nach Sequenzlänge aufsteigend sortiert ist, wird der beschriebene Algorithmus 2b) angewendet. Lediglich könnte die Iteration vorzeitig abgebrochen werden, wenn für ein Element die berechnete Sequenzlänge größer als die bisher bekannte minimale Länge ist. In diesem Fall wäre aufgrund der Sortierung sichergestellt, dass alle SMSS mit minimaler Länge gefunden wurden. Der Algorithmus 2b) müsste im Falle einer sortierten Ergebnismenge leicht angepasst werden, um diese Bedingung zu überprüfen und die Iteration gegebenenfalls abzubrechen.

2.3 2c - Alle MSS

Für die 2c haben wir unseren ursprünglichen Ansatz nicht weiter verwendet. Der *optimale Algorithmus* ist in sich selbst so effizient, dass er null Folgen am Anfang und am Ende von Segmenten direkt ignoriert. Wir haben uns also überlegt, welcher der anderen Algorithmen mit eine möglichst guten Laufzeit, diese Fälle auch betrachtet. Wir haben uns dazu entschieden den *dynamic programming Algorithmus* zu erweitern. Dieser hat nämlich den Vorteil bereits ohne Erweiterungen, alle Kombinationen von Teilintervallen zu betrachten. Insbesondere die Teilintervalle, die der *optimale Algorithmus* nicht in Betracht zieht. Im unteren Fallbeispiel sieht man, wie der *optimale Algorithmus* die Nullerpräfixe der MSS ignoriert:

```
Für Sequenz:            5 -5 9 -3 13 -5 5 -5 5
optimal             :   -----+=====+----------

tatsächliche MSS    :   -----+=====+----------
                        -----+==========+-----
                        -----+===============+
                        +==========+----------
                        +===============+-----
                        +====================+
```

Der *dynamic programming* Algorithmus betrachtet in dem oberen Beispiel alle der Teilfolgen. Also haben wir wieder wie in 2.1 eine äußere Liste mit inneren Listen erstellt, und für jeden neuen *maxscore* eine neue innere Liste erstellt, die dann mit allen gleichwertigen Segmenten (also allen Segmenten mit demselben *maxscore*) befüllt wird, bis ein größerer *maxscore* gefunden wird. So findet der *2_c Algorithmus* also definitiv alle MSS, denn wir wissen bereits, dass der *dynamic programming* Ansatz korrekt ist und alle Kombinationen in Betracht zieht. Jedoch bußt dieser Ansatz bei der Speicherkomplexität ein, das *int[][]* Array wächst zu einem gegebenen Eingabe Vektor mit Länge n exponentiell: n^2. D.h. für große Eingaben verbrauchen wir enorm viel Speicherplatz. Wie bereits in 1.2 gezeigt, benutzt der *dynamic programming* Ansatz immer nur die Hälfte des Arrays. Allgemein hat das Array die folgende Form:

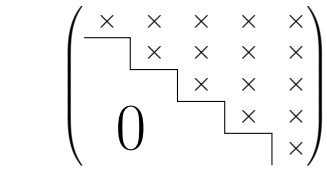

Betrachten wir die jeweiligen Endzustände der Datenstruktur S von Algorithmus *2_c* und der Arbeitsspeicher schonenden Variante *2_c_1*:

```
Eingabe: v = {5, -5, 9, -3, 13, -5, 5, -5, 5}
Array S[n][n] of Default Dynamic Programming (2_c) on v:
   0: [5 ,0 ,9 ,6 ,19,14,19,14,19]
   1: [0 ,-5,4 ,1 ,14,9 ,14,9 ,14]
   2: [0 ,0 ,9 ,6 ,19,14,19,14,19]
   3: [0 ,0 ,0 ,-3,10,5 ,10,5 ,10]
   4: [0 ,0 ,0 ,0 ,13,8 ,13,8 ,13]
   5: [0 ,0 ,0 ,0 ,0 ,-5,0 ,-5, 0]
   6: [0 ,0 ,0 ,0 ,0 ,0 ,5 , 0, 5]
   7: [0 ,0 ,0 ,0 ,0 ,0 ,0 ,-5, 0]
   8: [0 ,0 ,0 ,0 ,0 ,0 ,0 , 0, 5]

Max n on given Hardware: 30808:
java -jar SMSS.jar --algorithms 2_c --size 30808

Eingabe: v = {5, -5, 9, -3, 13, -5, 5, -5, 5}
ArrayList S containing int[] Arrays of Improved Dynamic Programming (2_c_1) on v:
   0: [5 ,0 ,9 ,6 ,19,14,19,14,19]
   1: [-5,4 ,1 ,14,9 ,14,9 ,14]
   2: [9 ,6 ,19,14,19,14,19]
   3: [-3,10,5 ,10,5 ,10]
   4: [13,8 ,13,8 ,13]
   5: [-5,0 ,-5,0]
   6: [5 ,0 ,5]
   7: [-5,0]
   8: [5]

Max n on given Hardware: 44069:
java -jar SMSS.jar --algorithms 2_c_1 --size 44069
```

Der *improved dynamic programming 2_c_1* hat keine Position in der Datenstruktur, die ungenutzt bleibt. Der verbesserte Ansatz schafft es 13261 zusätzliche Zahlen zu verarbeiten, also ein $\approx 43\%$ größeres n als der *default 2_c Algorithmus* (*auf der gegebenen Hardware). An der Komplexität hat sich durch die Abänderungen nichts geändert. In Abbildung 2 werden die zwei Ansätze in ihrer Laufzeit verglichen. Die Spikes in der Abbildung entstehen durch die inkonsistente Geschwindigkeit bei der Array Initialisierung.

3 Supplementary Material

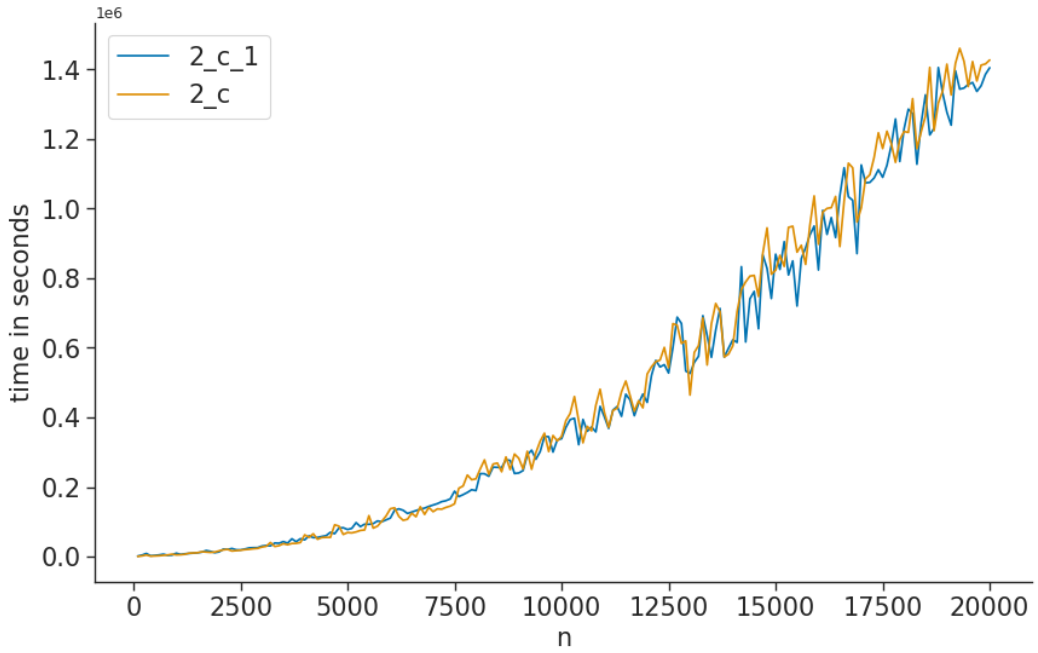

Figure 2: Ansatz 2_c verglichen mit dem Arbeitsspeicher optimierten Ansatz 2_c_1

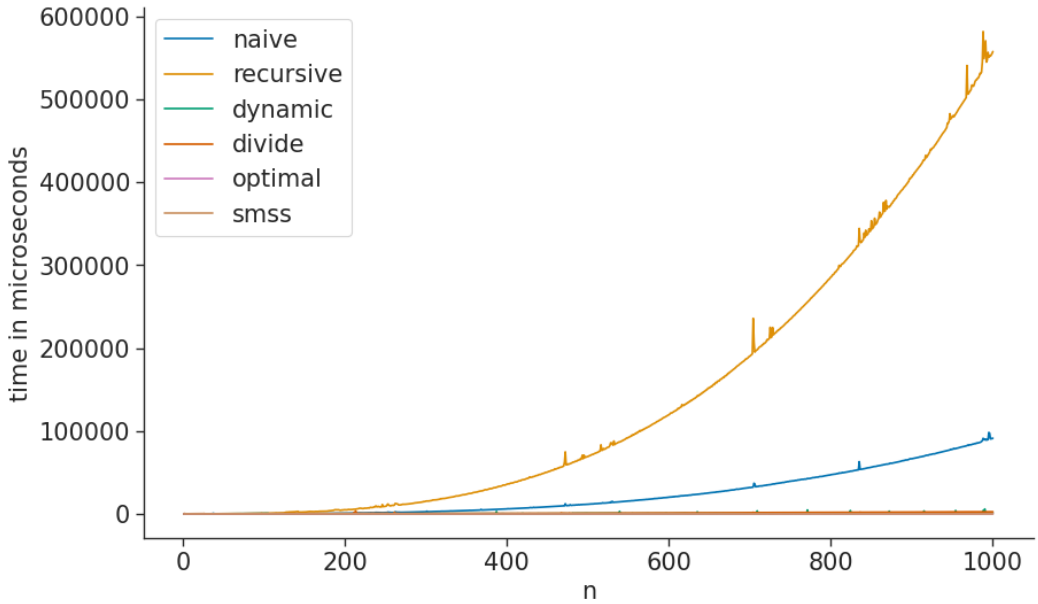

Figure 3: Überblick aller Algorithmen für Eingabeintervall [1; 1000]